Mini Project 01 - IMDB web scraping

```
library(tidyverse)
library(rvest)
Warning message in system("timedatectl", intern = TRUE):
"running command 'timedatectl' had status 1"
Warning message:
"Failed to locate timezone database"
— Attaching packages —
                                                       – tidyverse 1.3.1

✓ ggplot2 3.3.5

                  ✓ purrr 0.3.4
— Conflicts -
                                                  - tidyverse_conflicts()
* dplyr::filter() masks stats::filter()
* purrr::flatten() masks jsonlite::flatten()
* dplyr::lag() masks stats::lag()
Attaching package: 'rvest'
```

```
url <- "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"
```

```
print(url)
```

[1] "https://www.imdb.com/search/title/?groups=top_100&sort=user_rating,desc"

```
#read html
imdb <- read_html(url)</pre>
```

imdb

```
# read title
titles <- imdb %>%
  html_nodes("h3.lister-item-header") %>%
  html_text2()
```

titles[1:10]

```
'1. The Shawshank Redemption (1994)' · '2. The Godfather (1972)' · '3. The Dark Knight (2008)' ·
```

```
# rating
ratings <- imdb %>%
  html_nodes("div.ratings-imdb-rating") %>%
  html_text2() %>%
  as.numeric()
```

ratings[1:10]

^{&#}x27;4. Schindler\'s List (1993)' · '5. The Godfather Part II (1974)' · '6. 12 Angry Men (1957)' ·

^{&#}x27;7. The Lord of the Rings: The Return of the King (2003) '· '8. Pulp Fiction (1994) '· '9. Inception (2010) '·

^{&#}x27;10. Fight Club (1999)'

 $9.3 \cdot 9.2 \cdot 9 \cdot 9 \cdot 9 \cdot 9 \cdot 9 \cdot 8.9 \cdot 8.8 \cdot 8.8$

```
# number of vote
num_votes <- imdb %>%
  html_nodes("p.sort-num_votes-visible") %>%
  html_text2()
```

```
df <- data.frame(
    title = titles,
    rating = ratings,
    num_vote <- num_votes
)
head(df)</pre>
```

A data.frame: 6 × 3				
	title	rating	num_votenum_votes	
	<chr></chr>	<dbl></dbl>	<chr></chr>	
1	1. The Shawshank Redemption (1994)	9.3	Votes: 2,690,632 Gross: \$28.34M Top 250: #1	
2	2. The Godfather (1972)	9.2	Votes: 1,866,415 Gross: \$134.97M Top 250: #2	
3	3. The Dark Knight (2008)	9.0	Votes: 2,664,274 Gross: \$534.86M Top 250: #3	
4	4. Schindler's List (1993)	9.0	Votes: 1,360,785 Gross: \$96.90M Top 250: #6	
5	5. The Godfather Part II (1974)	9.0	Votes: 1,276,583 Gross: \$57.30M Top 250: #4	

Votes: 794,898 | Gross: \$4.36M | Top 250: #5

Mini Project 02 - Specphone Phone Database

9.0

```
library(tidyverse)
library(rvest) #scrape data from internet
```

6 6. 12 Angry Men (1957)

```
url <- read_html("https://specphone.com/Samsung-Galaxy-A04.html")</pre>
```

```
att <- url %>%
  html_nodes("div.topic") %>%
  html_text2()
```

```
value <- url %>%
  html_nodes("div.detail") %>%
  html_text2()
```

```
data.frame(
    attibute = att,
    value = value
)
```

A data.frame: 31 × 2

attibute	value		
<chr></chr>	<chr></chr>		
วันเปิดตัว	ตุลาคม 2565		
วันวางจำหน่าย	ยังไม่วางจำหน่าย		
ขนาด	164.40 x 76.30 x 9.10 มม.		
น้ำหนัก	192 กรัม		
วัสดุ	Glass front, plastic back, plastic frame		
SIM	รองรับ 2 ซิมการ์ต (nano sim, nano sim)		
Technology	HSPA 42.2/5.76 Mbps, LTE-A		
2G	850/900/1800/1900		
3G	850/900/1900/2100		
4G	850/900/1900/2100/2600		
5G	-		
ความเร็ว	HSPA 42.2/5.76 Mbps, LTE-A		
ประเภท	PLS LCD		
ขนาดหน้าจอ	6.50 นิ้ว		
ความละเอียด	720 x 1600 pixels		
ระบบปฏิบัติการ	Android 12		
ชิปประมวลผล	Spreadtrum Unisoc SC9863A 1.6 GHz		
ชิปกราฟิก	PowerVR GE8322		
หน่วยความจำ	3 GB		
ความจุ	32 GB		
Memory Card	microSD (1)		
กล้องหลัก	ตัวที่ 1: 50 MP, f/1.8, (wide), AF ตัวที่ 2: 2 MP, f/2.4, (depth)		
ความละเอียดวีดีโอ	1080p@30fps		
กล้องหน้า	ตัวที่ 1: 5 MP, f/2.2		
Bluetooth	5.0, A2DP, LE		
Wi-Fi	802.11 a/b/g/n/ac, dual-b		
USB	Type-C		
GPS	GLONASS, GALILEO, BDS		
NFC	ไม่รองรับ		
ความจุ	5,000 mAh		

```
# All samsung smartphone
samsung_url <- read_html("https://specphone.com/brand/Samsung")

# link to all samsung smartphone
links <- samsung_url %>%
    html_nodes("li.mobile-brand-item a") %>% ## CSS spector pull attribute in hre
    html_attr("href")

## so, find mobile-brand-item at li and go to a for pull attribute href
```

links

```
'/Samsung-Galaxy-M13.html' · '/Samsung-Galaxy-A23.html' · '/Samsung-Galaxy-A13.html' ·
'/Samsung-Galaxy-M32-5G.html' · '/Samsung-Galaxy-A12-Nacho.html' ·
'/Samsung-Galaxy-Pocket-Neo.html' · '/Samsung-Galaxy-Young.html' · '/Samsung-Galaxy-J1-Mini.html' ·
'/Samsung-Galaxy-A01-Core-1-16GB.html' · '/Samsung-Galaxy-V-PLUS.html' ·
'/Samsung-Galaxy-Young-2.html' · '/Samsung-Galaxy-M02.html' · '/Samsung-Galaxy-A11.html' ·
'/Samsung-Galaxy-J2-Pro-2018.html' · '/Samsung-Galaxy-A12-2021.html' ·
'/Samsung-Galaxy-A21s-3-32GB.html' · '/Samsung-Galaxy-J5.html' · '/Samsung-Galaxy-J4.html' ·
'/Samsung-Galaxy-Core-2-Duos.html' · '/Samsung-Galaxy-Ace-Plus.html' · '/Samsung-Galaxy-A20.html' ·
'/Samsung-Galaxy-Chat.html' · '/Samsung-Galaxy-Gio.html' · '/Samsung-Galaxy-Tab-A7-Lite-LTE.html' ·
'/Samsung-Galaxy-Tab-A-10.5WIFI.html' · '/Samsung-Galaxy-Alpha.html' · '/Samsung-Galaxy-S3-Slim.html' ·
'/Samsung-Galaxy-S4-zoom.html' · '/Samsung-Galaxy-Xcover-2.html' ·
'/Samsung-Galaxy-Tab-8.9-3G-16GB.html' · '/Samsung-Galaxy-Tab-A8-LTE-2021.html' ·
'/Samsung-Galaxy-M33-5G.html' · '/Samsung-Galaxy-A50.html' · '/Samsung-Galaxy-E7.html' ·
'/Samsung-Galaxy-S6.html' · '/Samsung-Galaxy-S20-FE.html' · '/Samsung-Galaxy-Tab-S4-WIFI.html' ·
'/Samsung-Galaxy-S7.html' · '/Samsung-Galaxy-Note-5-Exynos.html' ·
'/Samsung-Galaxy-TabPRO-12.2-LTE.html' · '/Samsung-Galaxy-S4-Active.html' ·
'/Samsung-Galaxy-Tab-Active-3.html' · '/Samsung-Galaxy-Tab-S3-9.7.html' ·
'/Samsung-Galaxy-S6-edge.html' · '/Samsung-Galaxy-Note-4-Exynos.html' ·
'/Samsung-Galaxy-Round.html' · '/Samsung-Galaxy-Note-20-Ultra-5G.html' · '/Samsung-ATIV-Q.html' ·
'/Samsung-ATIV-Smart-PC-PRO.html' · '/Samsung-Galaxy-S22-Ultra12-128GB.html' ·
'/Samsung-Galaxy-Z-Flip-5G.html' · '/Samsung-Galaxy-Z-Flip.html' ·
'/Samsung-Galaxy-Tab-S8-Ultra-5G.html' · '/Samsung-Galaxy-S21-Ultra-16-512GB.html' ·
'/Samsung-Galaxy-S10-Plus-Ram-12GB.html' · '/Samsung-Galaxy-Z-Fold-3.html' ·
'/Samsung-Galaxy-Z-Fold4.html' · '/Samsung-Galaxy-Z-Fold-2-5G.html'
```

```
full_links <- paste0("https://specphone.com", links )</pre>
```

```
result <- data.frame()</pre>
for (link in full_links[1:10]){
    ss_topic <- link %>%
            read_html %>%
            html_nodes("div.topic") %>%
            html_text2()
    ss_detail <- link %>%
             read_html() %>%
             html_nodes("div.detail") %>%
            html_text2()
    tmp <- data.frame(attribute = ss_topic,</pre>
                         value = ss_detail)
    result <- bind_rows(result, tmp)</pre>
    print("Progress..")
}
[1] "Progress.."
[1] "Progress.."
[1] "Progress.."
[1] "Progress.."
[1] "Progress.."
[1] "Progress.."
```

```
[1] "Progress.."
[1] "Progress.."
[1] "Progress.."
```

```
print(result)
```

```
attribute
1
             วันเปิดตัว
2
        วันวางจำหน่าย
3
                ขนาด
               น้ำหนัก
4
5
                  วัสด
                  SIM
6
7
         Technology
8
                   2G
9
                   3G
10
                   4G
                   5G
11
             ความเร็ว
12
13
              ประเภท
```

```
14 ขนาดหน้าจอ
15 ความละเอียด
16 ระบบปฏิบัติการ
17 ชิปประมวลผล
18 ชิปกราฟิก
```

```
print(head(result))
```

```
attribute
                                                       value
                                                มิถุนายน 2565
      วันเปิดตัว
1
2 วันวางจำหน่าย
                                              ยังไม่วางจำหน่าย
3
                                 165.40 x 76.90 x 8.40 มม.
          ขนาด
         น้ำหนัก
4
                                                     192 กรัม
5
           วัสดุ Glass front, plastic back, plastic frame
6
           SIM
                     รองรับ 2 ซิมการ์ด (nano sim, nano sim)
```

```
# write CSV
write_csv(result, "result_ss_phone.csv")
```